

* PAC Analysis for Bayesian estimators.

Notations. Learning sample $S := \{z_1, z_2, \dots, z_n\} \sim D^n$
Predictors (or hypothesis) $h: \mathcal{X} \rightarrow \mathcal{Y}$, $h \in \mathcal{H}$
Learning Algorithm $A(S) \rightarrow h$
loss function $\ell: \mathcal{H} \times \mathcal{Z} \rightarrow \mathbb{R}$

$$\text{Population Risk } R_D(h) = \mathbb{E}_{z \sim D} [\ell(h, z)]$$

$$\text{Empirical Risk } \hat{R}_S(h) = \frac{1}{n} \sum_{i \in [n]} \ell(h, z_i)$$

Goal: Population risk $R_D(h)$ 를 최소화하고 싶다.

하지만, 실제로는 Empirical risk $\hat{R}_S(h)$ 만 관측이 된다.

$\hat{R}_S(h)$ 로 $R_D(h)$ 를 Bound할 수 있을까?

Classical PAC Guarantees.

With probability at least $1 - \delta$, the risk of hypothesis $h \in \mathcal{H}$ is less than ε .

$$\mathbb{P}_{S \sim D^n} [R_D(h) \leq \varepsilon(\hat{R}_S(h), n, \delta, \dots)] \geq 1 - \delta.$$

• finite function class $\mathcal{H}$: $\forall h \in \mathcal{H}$, $R_D(h) \leq \hat{R}_S(h) + \sqrt{\frac{1}{2n} \log\left(\frac{|\mathcal{H}|}{\delta}\right)}$

• infinite function class $\mathcal{H}$: VC-Dimension, Rademacher complexity, ...

PAC-Bayesian Guarantees. (allows to consider distⁿ over hypothesis.)

Given a prior π on $\mathcal{H}$ and a posterior Q on $\mathcal{H}$,

$$\mathbb{P}_{S \sim D^n} [\mathbb{E}_{h \sim Q}(R_D(h)) \leq \varepsilon(\mathbb{E}_{h \sim Q}(\hat{R}_S(h)), n, \delta, \pi, \dots)] \geq 1 - \delta.$$

• 기존의 Bayesian: $\text{Prior} \xrightarrow[\text{modeling (likelihood)}]{\text{unique}} \text{Posterior}$

• PAC-Bayes.: $\text{data에 의존하지 않는 any dist}^n \xrightarrow[\text{loss에만 의존.}]{\text{model-free.}} \text{data에 의존하는 any dist}^n$

Rmk. 보통 h 는 θ 로 parameterize 되어 h_θ 로 표현된다. 그래서 간략하게,
 h_θ 를 θ 로, $\mathcal{H}$ 를 $\mathcal{P}(\Theta)$ 로 표현한다. 그리고, $\ell(h, z_i) = \ell_i(\theta)$ 로 표기한다.
 분포를 들고 있다는 맥각상 더 자연스러울 듯.

Thm. (Cantoni, 2003) (loss가 $[0, 1]$ 로 Bound 되어있다고 가정한다.)

Given a prior π on $\mathcal{P}(\Theta)$, for any $\lambda > 0$ and $\delta \in (0, 1)$,

$$\mathbb{P}_{S \sim \mathcal{D}^n} \left(\forall Q \sim \mathcal{P}(\Theta), \mathbb{E}_{\theta \sim Q} [R_D(\theta)] \leq \mathbb{E}_{\theta \sim Q} [\hat{R}_S(\theta)] + \frac{\lambda C^2}{8n} + \frac{KL(Q \| \pi) + \log \frac{1}{\delta}}{\lambda} \right) \geq 1 - \delta.$$

pf. 임의의 $\theta \in \Theta$ 를 고정하고, $U_i = \mathbb{E}_{z \sim \mathcal{D}} [\ell_i(\theta)] - \ell_i(\theta)$ 를 고려하자

그러면, $\frac{1}{n} \sum_{i=1}^n U_i = R_D(\theta) - \hat{R}_S(\theta)$ 이다. 이제 U_i 에 Hoeffding lemma를 적용하면,

$$\mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\pm \sum_{i=1}^n U_i \right) \right] \leq \exp \left(\frac{n \pm^2 C^2}{8} \right) \quad \forall \pm \geq 0$$

$$\Leftrightarrow \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\pm n (R_D(\theta) - \hat{R}_S(\theta)) \right) \right] \leq \exp \left(\frac{n \pm^2 C^2}{8} \right)$$

$$\Leftrightarrow \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\lambda (R_D(\theta) - \hat{R}_S(\theta)) \right) \right] \leq \exp \left(\frac{\lambda^2 C^2}{8n} \right) \quad (\because \pm = \lambda \text{ 제함.})$$

양변에 θ 에 대해 Prior를 기대값으로 취해주면,

$$\mathbb{E}_{\theta \sim \pi} \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\lambda (R_D(\theta) - \hat{R}_S(\theta)) \right) \right] \leq \exp \left(\frac{\lambda^2 C^2}{8n} \right)$$

$$\Leftrightarrow \mathbb{E}_{S \sim \mathcal{D}^n} \mathbb{E}_{\theta \sim \pi} \left[\exp \left(\lambda (R_D(\theta) - \hat{R}_S(\theta)) \right) \right] \leq \exp \left(\frac{\lambda^2 C^2}{8n} \right) \quad (\because \text{Tonelli})$$

$$\Leftrightarrow \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\sup_{Q \in \mathcal{P}(\Theta)} \lambda \mathbb{E}_{\theta \sim Q} [R_D(\theta) - \hat{R}_S(\theta)] - KL(Q \| \pi) \right) \right] \leq \exp \left(\frac{\lambda^2 C^2}{8n} \right) \quad (\because \text{DV lemma})$$

$$\Leftrightarrow \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\sup_{Q \in \mathcal{P}(\Theta)} \lambda \mathbb{E}_{\theta \sim Q} [R_D(\theta) - \hat{R}_S(\theta)] - KL(Q \| \pi) - \frac{\lambda^2 C^2}{8n} \right) \right] \leq 1$$

Chernoff bound에 의해, $\left(P(X \geq c) = P(e^X \geq e^c) \leq \frac{\mathbb{E}(e^X)}{e^c} \right)$

$$\mathbb{P}_{S \sim \mathcal{D}^n} \left[\sup_{Q \in \mathcal{P}(\Theta)} \lambda \mathbb{E}_{\theta \sim Q} [R_D(\theta) - \hat{R}_S(\theta)] - KL(Q \| \pi) - \frac{\lambda^2 C^2}{8n} > c \right]$$

$$\leq \mathbb{E}_{S \sim \mathcal{D}^n} \left[\exp \left(\sup_{Q \in \mathcal{P}(\Theta)} \lambda \mathbb{E}_{\theta \sim Q} [R_D(\theta) - \hat{R}_S(\theta)] - KL(Q \| \pi) - \frac{\lambda^2 C^2}{8n} \right) \right] e^{-c}$$

$$\leq e^{-c}$$

Take $e^{-c} = \delta$. 식 정리하면 증명 끝. $\square$

Rmk. (PAC-Bayes inspired predictors.)

PAC-Bayes Bound는 보통 아래와 같이 주해진다.

$$\mathbb{E}_{\theta \sim Q} [R_D(\theta)] \leq \mathbb{E}_{\theta \sim Q} [\hat{R}_S(\theta)] + \text{complexity terms.}$$

그러면 반대로, 다음의 posterior를 고려해보기도 있을 것이다.

$$Q^* \in \operatorname{argmin}_{Q \in \mathcal{P}(\Theta)} \left[\mathbb{E}_{\theta \sim Q} [\hat{R}_S(\theta)] + \text{complexity terms.} \right]$$

Cantoni Bound에서처럼, $\mathbb{E}_{\theta \sim Q} [\hat{R}_S(\theta)] + \frac{KL(Q \parallel \pi)}{\lambda}$ 의 minimizer도 고려할 수 있을 것이다. 그러한 Q^* 는 아래와 같고, 이를 Gibbs Posterior라고 한다.

$$\rightarrow Q_\lambda(\theta) \propto \exp(-\lambda \hat{R}_S(\theta)) \pi(\theta)$$

(i) loss가 $-\log$ -likelihood이면 classical한 Bayesian이다.

(ii) $\lambda \rightarrow 0$: prior

$\lambda \rightarrow \infty$: Dirac mass on ERM.

ex. (Neural Networks.)

Given a model / predictor h_θ (θ : weight on NN)

• $\pi = N(\theta_0, \tau_0 I)$ θ_0 는 pretrained된 NN weights

• $Q = N(\theta, \tau I)$ θ 는 fine-tuned된 NN weights.

$$\leadsto KL(Q \parallel \pi) = \frac{1}{2} \|\theta - \theta_0\|^2$$

Rmk. (averaged predictors) $h_Q(\cdot) := \mathbb{E}_{\theta \sim Q} [h_\theta(\cdot)]$

(single-draw) $h_{\hat{\theta}}(\cdot)$ where $\hat{\theta} \sim Q$.

만약 $\theta \mapsto \ell(\mathbf{x}, \theta)$ 가 convex하다면, Jensen의 부등식에 의해,

$$\mathbb{E}_{\theta \sim Q} [R(h_\theta)] \geq R(\mathbb{E}_{\theta \sim Q} (h_\theta)) = R(h_Q) \text{이다.}$$

Averaged Predictor의 경우에는 expected risk는 실제 risk를 control할 수 있다.

* Sharpness aware minimization (ICLR, 2021.)

PAC inspired algorithm의 한 예시인 SAM을 보자.

논문에서는 parameter θ 에 perturbation ε 을 주었으며, PAC-Bayes Bound를 증명했다.

Thm. (stated informally.)

For any $\rho > 0$, with high probability over training set $S \sim D^n$,

$$R_D(\theta) \leq \max_{\|\varepsilon\|_2 \leq \rho} \hat{R}_S(\theta + \varepsilon) + h(\|\theta\|_2^2 / \rho^2)$$

(여기서 prior $\pi \sim N(\theta_0, \sigma_0^2 I)$, posterior $Q \sim N(\theta, \sigma^2 I)$ 로 두었고,
다소 강하지만... $R_D(\theta) \leq \mathbb{E}_{u \sim Q} R_D(u)$ 라고 가정하였다. (convex 대신.))

그런 Cantoni bound에서 한 것처럼 이제 Bound에서 inspired 된 algorithm을 생각해볼 수 있다.

$$\theta^* = \min_{\theta} \left[\max_{\|\varepsilon\|_2 \leq \rho} \hat{R}_S(\theta + \varepsilon) + h(\|\theta\|_2^2 / \rho^2) \right]$$

적절한 ε 은 아래와 같이 찾을 수 있다.

$$\begin{aligned} \hat{\varepsilon} &= \arg \max_{\|\varepsilon\|_2 \leq \rho} \hat{R}_S(\theta + \varepsilon) \approx \arg \max_{\|\varepsilon\|_2 \leq \rho} \hat{R}_S(\theta) + \varepsilon^T \nabla_{\theta} \hat{R}_S(\theta) \\ &\approx \arg \max_{\|\varepsilon\|_2 \leq \rho} \varepsilon^T \nabla_{\theta} \hat{R}_S(\theta) \end{aligned}$$

한편, 이는 dual norm 문제로 풀 수 있다. (Hölder 부등식의 등식 성립 조건.)

* Tighter PAC-Bayes Bounds.

$$\text{def. } \text{kl}(p \parallel q) := p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q} = \text{kl}(\text{Ber}(p) \parallel \text{Ber}(q))$$

Thm. (Mauer, 2004) (also known as "Seeger's Bound.")

$$\begin{aligned} \mathbb{P}_{S \sim \mathcal{D}^n} [\forall Q \in \mathcal{P}(\Theta), \text{kl}(\mathbb{E}_{\theta \sim Q} [\hat{R}_S(\theta)] \parallel \mathbb{E}_{\theta \sim Q} [R_\theta(\theta)]) \\ \leq \frac{\text{kl}(Q \parallel \pi) + \log \frac{2\sqrt{n}}{\delta}}{n}] \geq 1 - \delta. \end{aligned}$$